Atividade: “Computing Machinery and Intelligence” (Turing, 1950)

Dados Não Estruturados · Augusto Blois

1. Como o jogo da imitação se relaciona com a forma como avaliamos sistemas de PLN?

Turing acha a pergunta “as máquinas podem pensar?” vaga demais, porque depende de definir o que é “pensar”. Então ele troca por um teste prático: se um interrogador, conversando só por texto, não consegue diferenciar a máquina de uma pessoa, a máquina passou. Ou seja, ele passa a julgar a máquina pelo comportamento, e não pelo que acontece dentro dela.

No PLN a gente avalia modelos basicamente do mesmo jeito. Benchmarks como GLUE e MMLU não tentam descobrir se o modelo “entende” a linguagem, eles só medem se ele acerta as tarefas. E tem avaliações bem parecidas com o jogo original, como o Chatbot Arena, onde as pessoas comparam respostas de dois modelos sem saber qual é qual. O problema dessa abordagem é que um modelo pode ir bem no teste sem realmente ser bom, seja por ter visto as respostas no treino ou por escrever de um jeito convincente mesmo quando está errado.

2. Como as objeções da consciência e da informalidade do comportamento reaparecem hoje?

A objeção da consciência diz que não basta a máquina produzir um bom texto, ela teria que sentir e saber o que está fazendo. Turing responde que, se fosse assim, a gente também não poderia ter certeza de que outras pessoas pensam, e mesmo assim assume que elas pensam. Essa discussão voltou com os LLMs: muita gente diz que modelos como GPT e LLaMA são “papagaios estocásticos”, que só juntam palavras por probabilidade sem entender nada. Ao mesmo tempo, teve o caso de um engenheiro do Google que achou que o LaMDA era consciente só pela forma como ele conversava.

A objeção da informalidade diz que é impossível escrever regras para tudo que uma pessoa faz, então humanos não seriam máquinas. Turing responde que não ter as regras escritas não quer dizer que não existam padrões por trás do comportamento. Isso tem muito a ver com a história do PLN: os sistemas antigos baseados em regras escritas à mão não davam conta da linguagem real, e modelos como BERT e GPT resolveram isso aprendendo os padrões direto dos dados. Mas a objeção ainda aparece de outro jeito, porque como ninguém escreveu essas regras, ninguém sabe exatamente o que o modelo aprendeu, e daí vêm as alucinações e os comportamentos inesperados.

3. Como a ideia da “child machine” se conecta com o treinamento em PLN?

Turing sugere que, em vez de programar uma mente adulta pronta, seria mais fácil criar uma máquina parecida com a mente de uma criança, quase vazia, e ensinar ela com o tempo, usando recompensas e punições. É bem parecido com o que se faz hoje. Um modelo como o GPT começa com pesos aleatórios, ou seja, sem saber nada. No pré-treinamento ele aprende lendo uma quantidade enorme de texto, depois passa pelo fine-tuning com exemplos escolhidos, que seria como a “educação”. Por fim, no RLHF, pessoas avaliam as respostas e o modelo é recompensado pelas boas e penalizado pelas ruins, que é praticamente a ideia de Turing.

A diferença é que uma criança aprende a falar com muito menos exemplos e interagindo com o mundo, enquanto os modelos precisam de bilhões de palavras e aprendem praticamente só com texto. Mesmo assim, Turing acertou que o caminho seria fazer a máquina aprender em vez de programar tudo na mão.