DADOS NÃO ESTRUTURADOS · UFPB · CIÊNCIA DE DADOS

DevIA Radar

Pergunta de pesquisa (primeira versão) e apresentação do projeto

Dupla: Augusto Blois e Pedro Flávio Nogueira Ribeiro de Luna · Tema 1 (Engenharia de Software) · Setembro de 2026

1. Pergunta de pesquisa (primeira versão)

> **Como desenvolvedores discutem o uso de Inteligência Artificial no desenvolvimento de software: quais ferramentas citam, sobre quais problemas falam e com que tom?**

Para tornar a pergunta mensurável, ela foi dividida em quatro perguntas específicas:

1. **Ferramentas:** quais ferramentas de IA (Claude, ChatGPT, GitHub Copilot, Cursor, Gemini etc.) aparecem com mais frequência nas discussões?
2. **Temas:** quais assuntos e pontos de atrito dominam essas discussões (geração de código, revisão de código, alucinação do modelo, integração com ferramentas)?
3. **Sentimento:** o tom das discussões é mais positivo ou negativo, e esse tom muda de uma ferramenta para outra?
4. **Evolução:** o volume e o tom dessas discussões mudam ao longo do tempo?

Nas etapas seguintes, a mesma pergunta será comparada entre formatos diferentes: o que desenvolvedores escrevem em issues (texto) confirma ou contradiz o que falam em podcasts (áudio) e palestras (vídeo)?

2. Sobre o projeto

Contexto e motivação

Ferramentas de IA generativa passaram a fazer parte do dia a dia de quem programa. Boa parte do que se lê sobre elas vem de anúncios e de conteúdo de marketing. O projeto busca a visão de quem usa essas ferramentas no trabalho, a partir de textos escritos pelos próprios desenvolvedores, sem filtro comercial.

Fonte de dados

A fonte principal da Etapa 1 são **issues do GitHub** (relatos de problemas, dúvidas e sugestões abertos em repositórios públicos), coletadas pela GitHub Search API. É texto não estruturado real: mistura linguagem natural com trechos de código, logs de erro, links e formatação markdown, o que exige limpeza antes de qualquer análise.

Etapas e técnicas

Etapa	Tipo de dado	Técnicas

1	Texto (issues do GitHub)	Coleta via Web API, expressões regulares para limpeza e extração, spaCy (lematização, classes gramaticais, entidades nomeadas, bigramas) e análise de sentimento com VADER
2	Áudio (podcasts e entrevistas)	Transcrição e análise do conteúdo falado sobre IA no desenvolvimento
3	Vídeo (palestras e vídeos técnicos)	Extração e análise do conteúdo de vídeos sobre o mesmo tema

Primeiros indícios (Etapa 1)

A primeira coleta reuniu 979 issues úteis de 633 repositórios. Os resultados iniciais já ajudam a delimitar a pergunta:

- Claude (305 issues), ChatGPT (302) e GitHub Copilot (169) são as ferramentas mais citadas;
- o tom geral é positivo: 65,5% das issues positivas contra 30,5% negativas;
- "review" é o segundo termo mais frequente do corpus, o que sugere a revisão de código como principal ponto de atrito;
- o volume de issues sobre o tema cresceu cerca de 11 vezes entre janeiro de 2025 e setembro de 2026.

Limitações conhecidas

A Search API do GitHub favorece conteúdo recente, então parte do crescimento observado é viés de amostragem. Os modelos usados (spaCy `en_core_web_sm` e VADER) foram treinados com textos de notícia e redes sociais e erram em vocabulário técnico, por exemplo ao ler "critical" ou "fatal" como palavras negativas. Essas limitações serão consideradas na versão final da pergunta.