DevIA Radar

Como desenvolvedores discutem Inteligência Artificial no desenvolvimento de software

Etapa 2 · Análise de áudio com librosa e Whisper · iTunes Search API

Augusto Blois · Pedro Flávio Nogueira Ribeiro de Luna
Dados Não Estruturados · UFPB · 2026

14
episódios de 14 podcasts

10 h
de áudio analisado

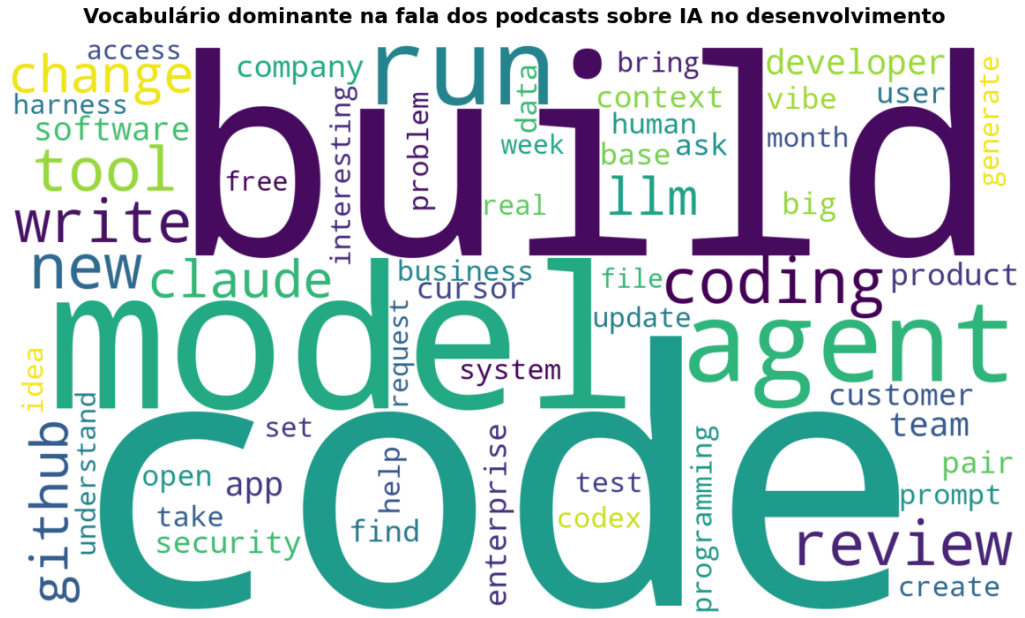
104.503
palavras transcritas

O que esta etapa investiga

Os desenvolvedores falam de IA do mesmo jeito que escrevem sobre ela?

Por que podcasts

- No podcast, o desenvolvedor fala de IA em conversa.
- O áudio traz duas camadas: a voz (energia, altura, pausas) e o texto, que o Whisper transcreve.
- A iTunes Search API é pública, gratuita e devolve JSON, como a API do GitHub na etapa 1.



Vocabulário da fala nos 14 episódios, depois do mesmo filtro do spaCy da etapa 1.

7
termos de busca

10.691
frases faladas

180
palavras por minuto

code e build lideram a fala. O review, segundo lugar no texto das issues, cai para oitavo: na conversa, o desenvolvedor fala mais de construir que de revisar.

Teoria e parâmetros

Três técnicas, aplicadas em sequência sobre o mesmo áudio

1 librosa

- Som digital é uma lista de números: 16.000 por segundo.
- Quadro: 25 ms de som, medidos a cada 10 ms.
- Mel: energia por faixa de frequência, na escala do ouvido.
- MFCC resume o timbre em 13 números, e o YIN mede a altura da voz (F0).

2 Whisper

- Rede neural treinada com 680 mil horas de áudio.
- Lê janelas de 30 s e escreve o texto com marca de tempo.
- Beam search: guarda as 5 melhores frases parciais a cada passo.
- hotwords: os nomes das ferramentas entram em toda janela.

3 Texto da fala

- Regex, spaCy e VADER da etapa 1, agora frase a frase.
- Escore z: quantos desvios-padrão a voz está acima da média do episódio.
- Spearman: mede se a voz sobe junto com o sentimento.

Parâmetros do projeto

7 termos de busca · 20 a 60 min · 16 kHz · 64 bandas Mel · 13 MFCC · F0 de 65 a 400 Hz · pausa longa ≥ 0,7 s · Whisper small, feixe 5

Implementação 1: librosa

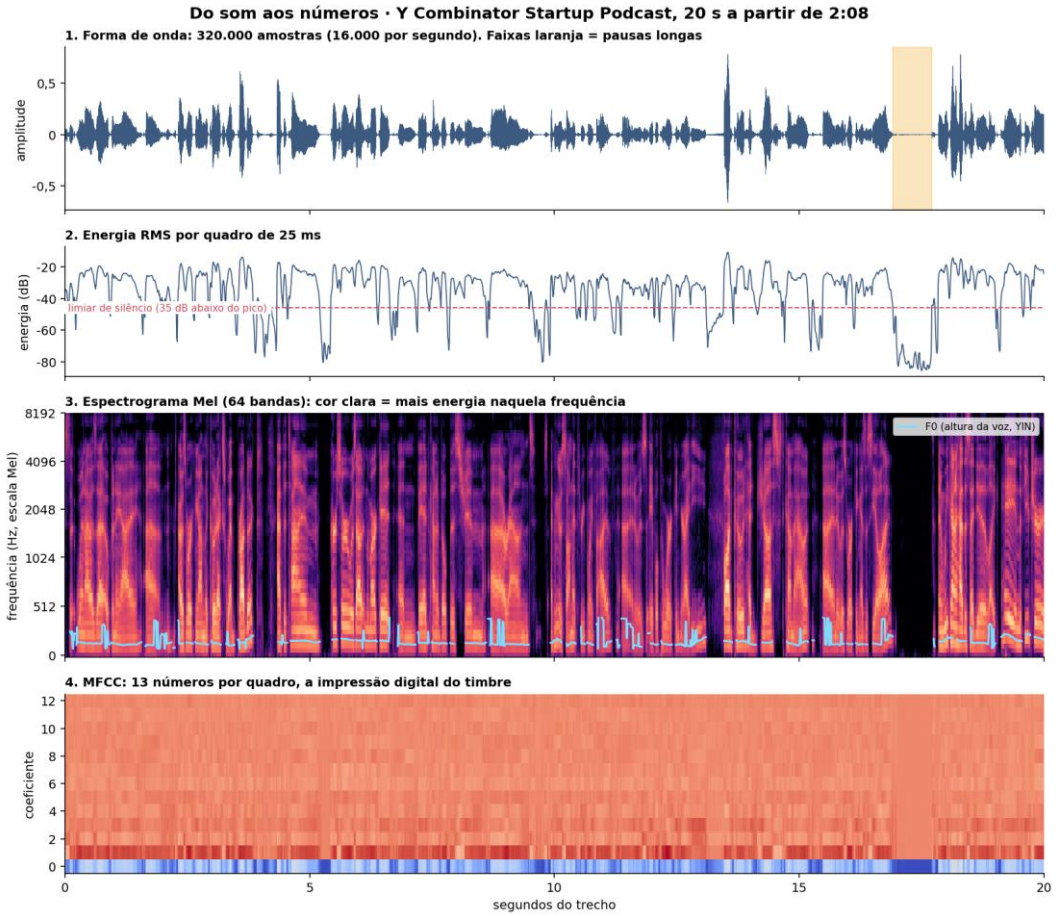
Arquivo sinal.py: o áudio vira uma tabela com 100 linhas por segundo

```
# quadro de 25 ms (400 amostras), um a cada 10 ms
rms = librosa.feature.rms(y=sinal,
          frame_length=400, hop_length=160)[0]
mel = librosa.feature.melspectrogram(y=sinal,
          sr=16000, n_fft=512, n_mels=64)
mfcc = librosa.feature.mfcc(S=mel_db, n_mfcc=13)
f0 = librosa.yin(sinal, fmin=65, fmax=400, sr=16000)
```

Cada linha devolve um valor por quadro, 100 por segundo. O Mel separa bem os graves e mal os agudos, como o ouvido, e o MFCC resume as 64 bandas em 13 números.

Onde aprender

librosa.org/doc/latest/tutorial.html, o tutorial oficial



Saída da opção 3: o mesmo trecho de 20 s como onda, energia, Mel e MFCC.

Implementação 2: Whisper

Arquivo transcricao.py: o áudio vira frases com marca de tempo




```
segmentos, _ = modelo.transcribe(sinal,
    language="en", beam_size=5,
    vad_filter=True,        # pula o silêncio
    hotwords=vocabulario)   # nomes das ferramentas
```

- O encoder lê o Mel da janela inteira, e o decoder escreve o texto uma palavra por vez.
- vad_filter: um detector de voz corta o silêncio, e o modelo não inventa texto onde ninguém fala.
- hotwords: a lista de nomes entra na frente de toda janela de 30 s.

Onde aprender: github.com/SYSTRAN/faster-whisper, o motor usado aqui

SEM A LISTA DE NOMES

I think it was **Sonic** 3.5, and it was able...
FODCode had just come out, and it was...

COM A LISTA (hotwords)

I think it was **Sonnet** 3.5, and it was able...
Claude Code had just come out, and it was...

CLAUDE NOS 10 PRIMEIROS MINUTOS DO EPISÓDIO

vocabulário	"Claude" certo	"cloud" (erro)
nenhum	13	3
initial_prompt	4	11
hotwords	**16**	**0**

Diário de bordo

Quatro erros que apareceram na implementação, e o que cada um exigiu

1. **O VADER contava a muleta "like" como elogio**

   "like" saiu do léxico nas duas mídias. Fala positiva: de 40% para 31%

2. **O Whisper escrevia "cloud" onde o podcast dizia "Claude"**

   O initial_prompt piorou (4 acertos, 11 erros). O hotwords zerou o erro

3. **A unidade de medida invertia a comparação**

   Issue de 311 palavras contra trecho de 11. A frase virou a unidade das duas

4. **O dicionário da etapa 1 não enxergava o Cursor**

   Uma regra por mídia: maiúscula no texto, qualquer caixa na fala

O erro 1 invertia a conclusão sem dar nenhum aviso

Com o "like" valendo "gostar", a fala parecia mais positiva que o texto.

Na fala, "like" aparece 16 vezes a cada mil palavras, e só 4% delas são verbo.

Sem ele, a fala tem menos frases positivas que o texto, e muito menos negativas.

Antes e depois de cada correção

Fala positiva

40% → 31%

Cursor na fala (frases)

1 → 105

Texto neutro

4% → 41%

Demonstração

python main.py: menu com 10 opções, áudio e transcrições em cache, roda sem internet

3

O som em números

Onda, Mel e MFCC de 20 s do Y Combinator, e ouvir o trecho

5

Whisper ao vivo

O mesmo trecho sem e com a lista: Sonic vira Sonnet

9

Busca KWIC

Padrão hallucinat\w+ e ouvir o momento achado

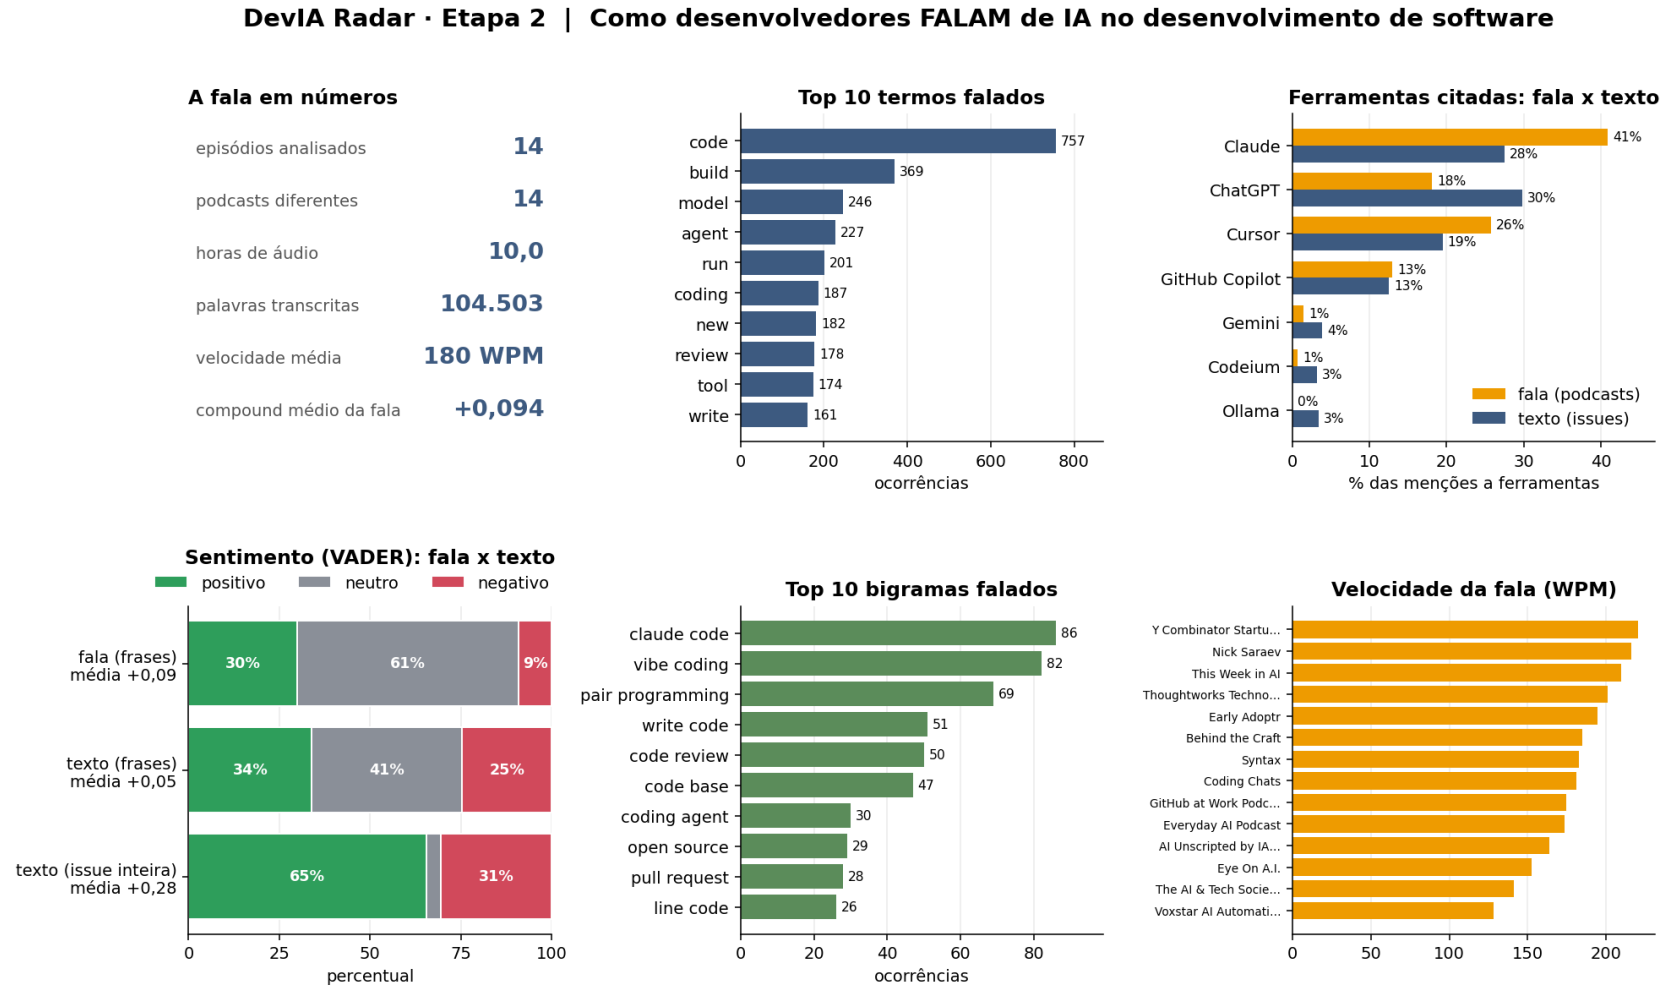
8

Dashboard

Os 8 gráficos gerados na pasta saida/

```
DevIA Radar - Etapa 2 (áudio) - UFPB
estado: episódios:14 | áudio:14 | fala:ok
----------------------------------------
 [1] Coletar episódios (iTunes API)
 [2] Ver resumo dos episódios
 [3] Demonstrar o sinal e ouvir
 [4] Extrair características acústicas
 [5] Demonstrar a transcrição ao vivo
 [6] Transcrever todos os episódios
 [7] Analisar a fala
 [8] Gerar gráficos e dashboard
 [9] Buscar palavra na fala (KWIC)
 [0] Rodar o pipeline completo
 [r] Recoletar do zero
 [s] Sair
```

Resultados



Dashboard da opção 8: termos, ferramentas, sentimento e velocidade da fala, com o texto da etapa 1 ao lado.

Claude domina a fala

41% das menções a ferramentas nos podcasts. No texto das issues, 28%.

A fala quase não reclama

9% de frases negativas na fala, contra 25% no texto das issues.

A voz não segue o tom

Energia da voz e sentimento: ρ = −0,025. A frase negativa não sai mais alta.

Ressalva: 14 episódios, um por podcast, e quem fala muda o tom. O podcast oficial do GitHub é o mais positivo (+0,28).

Limitações assumidas

A amostra é pequena

14 episódios, um por podcast. A busca da Apple muda todo dia, e recoletar muda a amostra.

O VADER foi feito para texto escrito

Não conhece o domínio: "security" vale +1,4 no léxico, mas na fala é só um termo técnico.

Dois podcasts podem ter voz sintética

Voxstar e Danar não declaram. Tirar episódio por palpite seria escolher a amostra pelo resultado.

Próximas etapas

3

Vídeo

Palestras da FOSDEM: o OCR lê o que está na tela, e o Whisper, o que é dito.

?

A pergunta que fica

Numa palestra preparada, o tom de quem fala fica mais perto da issue ou do podcast?

→

Consolidação

Um painel com texto, fala e vídeo lado a lado, medidos com a mesma régua.