DevIA Radar

Como desenvolvedores discutem Inteligência Artificial no desenvolvimento de software

Etapa 3 · Análise de vídeo com OpenCV, OCR e Whisper · FOSDEM

Augusto Blois · Pedro Flávio Nogueira Ribeiro de Luna
Dados Não Estruturados · UFPB · 2026

8

palestras da FOSDEM 2025 e 2026

3,3 h

de vídeo analisado

320

telas lidas pelo OCR

O que esta etapa investiga

Numa palestra sobre IA no desenvolvimento, o que aparece na tela e o que é dito?

Por que palestras da FOSDEM

- A palestra junta duas fontes no mesmo relógio: o que aparece na tela e o que o palestrante diz.
- A FOSDEM grava quase mil palestras por ano e publica a agenda em XML, com licença aberta.
- Cada vídeo tem uma legenda oficial, que dá para comparar com a transcrição do Whisper.

1.944
palestras com vídeo

27
com IA no título

8
passam nas regras



8 telas de cada palestra, com a moldura na cor do tipo que o OCR leu.

Das 27 com IA no título, só 8 falam de usar IA para desenvolver software. As outras tratam de servidor de modelo, dataset, filtro de spam e até de mouse antigo.

Teoria e parâmetros

Três técnicas, aplicadas em sequência sobre o mesmo vídeo

1 OpenCV

- Vídeo é uma pilha de imagens, e cada quadro é uma matriz de pixels.
- Diferença entre quadros: quanto o slide mudou, de 0 a 255.
- Canny: marca onde o brilho muda de repente, como na borda de uma letra.
- YuNet: rede neural que acha rostos na imagem da câmera.

2 RapidOCR

- Uma rede neural acha onde há texto, e outra lê cada linha.
- Cada linha lida vem com uma confiança de 0 a 1.
- Pelo texto e pelo brilho, a tela vira texto, visual, código ou interface.

3 Whisper

- O mesmo modelo da etapa 2, com a lista de nomes.
- A nossa transcrição é comparada com a legenda oficial.
- Cada frase recebe o tipo da tela do mesmo segundo.

Parâmetros do projeto

1 quadro por segundo · troca de slide: diferença > 6 · tela: 3 s parada · Canny 100 e 200 · confiança ≥ 0,6 · código: escura ou 15% das linhas

Implementação 1: OpenCV

Arquivo quadros.py: um quadro por segundo, recortado em slide e câmera

```
for segundo, quadro in percorrer(caminho):  # 1 por s
    slide = recortar(quadro, config.REGIAO_SLIDE)
    camera = recortar(quadro, config.REGIAO_CAMERA)
    dif = cv2.absdiff(mini, anterior)[mascara].mean()
    if dif > config.LIMIAR_TROCA:  # 6 de 255
        inicio_da_tela = segundo
    _, rostos = detector.detect(camera)  # YuNet
```

absdiff subtrai, pixel a pixel, o slide de agora do slide de um segundo antes. A máscara apaga o canto em que a câmera fica por cima do slide. Média acima de 6: o slide trocou.

Onde aprender

docs.opencv.org, os tutoriais oficiais do OpenCV em Python



ROSTO ACHADO EM 96 QUADROS DA CÂMERA

20 com o Haar cascade, de 2001

79 com o YuNet, rede neural de 2023

Implementação 2: OCR e tipo de tela

Arquivo leitura.py: o que está escrito na tela e o que é dito no mesmo segundo

tela parada 3 s → **acha o texto** → **lê cada linha** → **conta linhas** → **tipo de tela**

```
if palavras < 10:
    return "visual"            # foto, meme
if linhas >= 50 or (escura and linhas >= 30):
    if escura or fracao_codigo >= 0.15:
        return "código"
    return "interface"         # GitHub, n8n
return "texto"
```

- Slide é feito para ser lido do fundo da sala: poucas linhas de letra grande. Editor e site têm dezenas de linhas miúdas.
- Conferido à mão: 48 de 48 nas telas usadas para escolher os limites, 29 de 32 nas sorteadas.

Onde aprender: github.com/RapidAI/RapidOCR, o OCR usado aqui

NA TELA (OCR)

Claude Hardware Testing Infrastructure

NOSSA TRANSCRIÇÃO (WHISPER COM A LISTA)

Guide you through what I've done with **Claude**
on the hardware testing infrastructure.

LEGENDA OFICIAL DA FOSDEM

try to guide you through what I've done but
with the **cloth** on the hard work testing

44
nomes só na nossa transcrição

0
nomes só na legenda oficial

Diário de bordo

Quatro erros que apareceram na implementação, e o que cada um exigiu

1

O classificador achava 3 telas de código em 320

Contar linhas resolveu: 63 telas de código, 29 de 32 certas na conferência

2

A lista de nomes acerta "cloth" e inventa "Claude striked"

33 erros da legenda corrigidos e 6 erros nossos, como OpenAPI virando OpenAI

3

O detector de rosto clássico não achava o palestrante

Haar cascade: 20 rostos em 96 quadros. YuNet, nos mesmos quadros: 79

4

O "Gemini" escrito na tela era o botão do navegador

31 das 34 telas com Gemini mostram o botão do Chrome

O erro 2 tem dois lados: a lista acerta e inventa

Ela corrige 33 nomes que a legenda oficial errou, como "cloth" no lugar de Claude, 11 vezes numa palestra só.

E também inventa 6, como "Claude striked" no lugar de "CrowdStrike".

Toda ajuda ao modelo puxa os sons parecidos para as palavras dela: é preciso medir o ganho e o custo.

Antes e depois de cada correção

Telas de código

3 → 63

Rostos em 96 quadros

20 → 79

Gemini na tela (o modelo)

34 → 3

Demonstração

python main.py: menu com 10 opções, vídeo e leituras em cache, roda sem internet

3

Um quadro em números

Regiões, diferença, bordas e rostos: Haar contra YuNet

5

Tela, fala e legenda

OCR, Whisper e a legenda oficial no mesmo trecho de 20 s

9

Busca KWIC

Padrão claude na fala e na tela, e abrir o momento 6

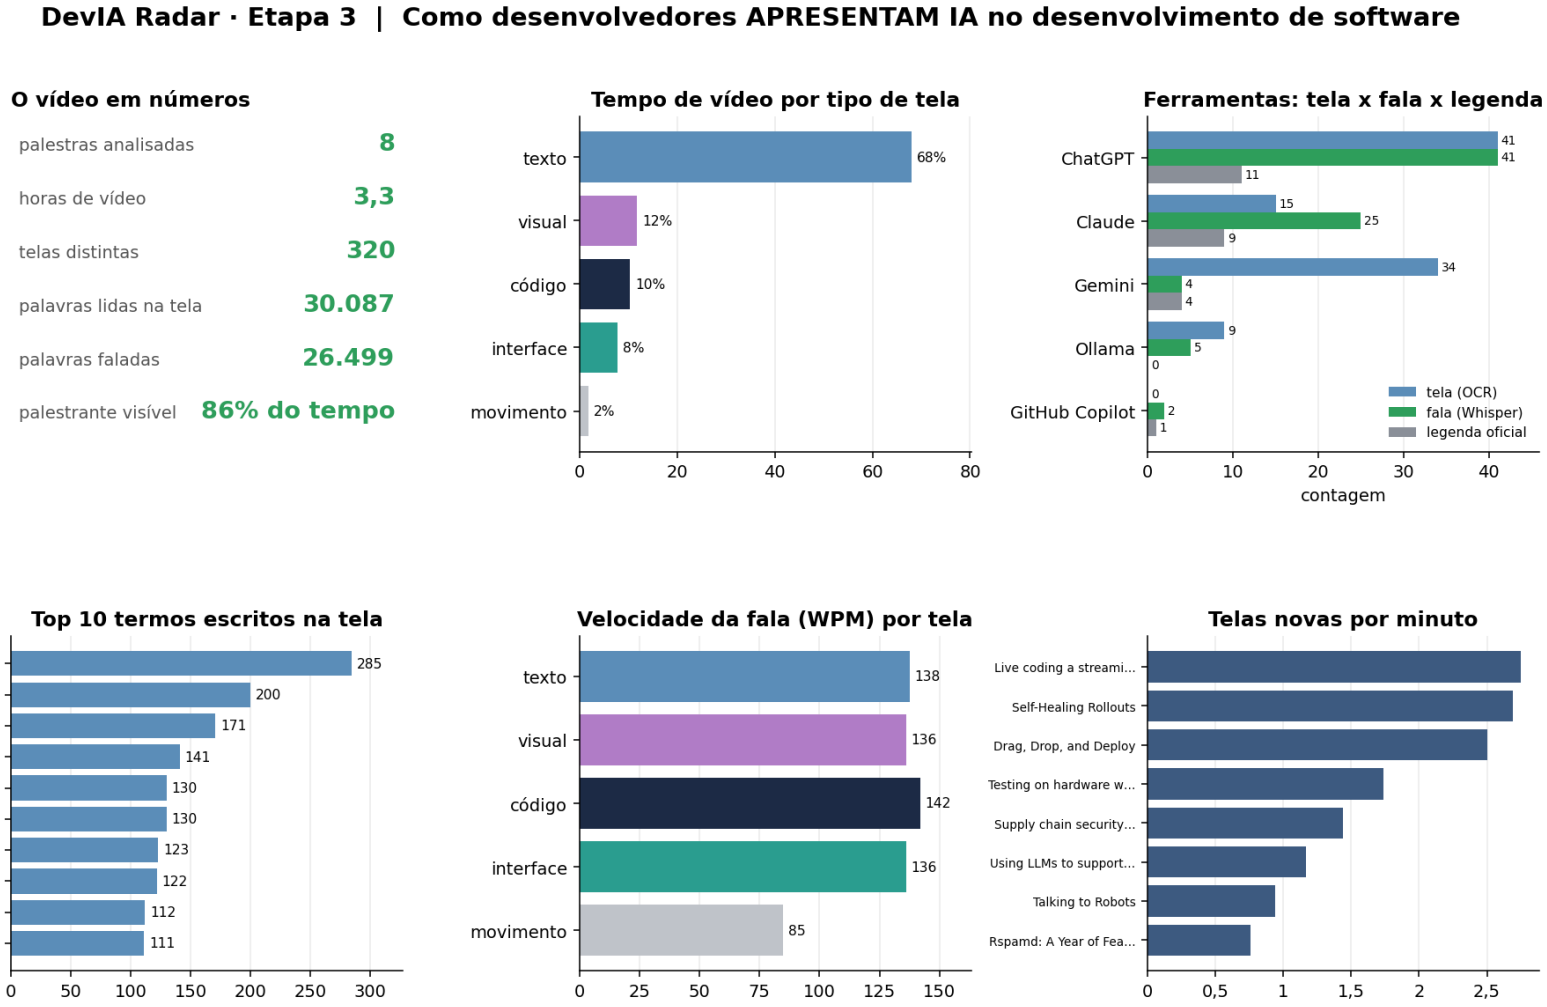
8

Dashboard

Os 9 gráficos, com o painel das três etapas

```
DevIA Radar - Etapa 3 (vídeo) - UFPB
estado: palestras:8 | vídeo:8 | análise:ok
----------------------------------------
 [1] Coletar palestras (agenda XML)
 [2] Ver resumo das palestras
 [3] Demonstrar um quadro (OpenCV)
 [4] Extrair características visuais
 [5] Demonstrar tela, fala e legenda
 [6] Ler as telas e transcrever
 [7] Analisar tela, ferramentas e fala
 [8] Gerar gráficos e painel
 [9] Buscar na fala e na tela (KWIC)
 [0] Rodar o pipeline completo
 [r] Recoletar do zero
 [s] Sair
```

Resultados



Dashboard da opção 8: tipo de tela, ferramentas, termos escritos, velocidade da fala e ritmo das telas.

A tela é quase toda slide

80% do tempo é slide: 68% de texto e 12% visual. Captura de ferramenta: 18%.

O tom vem de quem fala

O slide visual parecia mais emotivo, mas 141 das 193 frases ditas com ele são de uma palestra só.

A lista ganha da legenda

44 nomes só na nossa transcrição, nenhum só na legenda oficial.

Ressalva: são 8 palestras. 34 das 38 frases com ChatGPT vêm de uma só, que constrói um proxy do ChatGPT.

Limitações assumidas

8 palestras: todas as que passam nas regras

A ferramenta mais citada segue o tema de uma palestra.

O tempo de captura é um piso

3 das 32 telas da conferência eram capturas curtas lidas como slide.

A legenda oficial também é automática

A comparação mede o efeito da lista. Nenhuma das duas é gabarito.

As três etapas

1

Texto: 979 issues

34% positivas, 25% negativas. ChatGPT lidera, com 30%.

2

Fala: 14 podcasts

30% positivas, 9% negativas. Claude lidera, com 41%.

3

Vídeo: 8 palestras

25% positivas, 9% negativas. ChatGPT lidera, com 51%.

A reclamação mora no texto: 25% das frases das issues são negativas, contra 9% na fala.