DevIA Radar

Como desenvolvedores discutem Inteligência Artificial no desenvolvimento de software

Etapa 3 · Análise de áudio e vídeo com OpenCV, librosa, OCR e Whisper · FOSDEM

Augusto Blois · Pedro Flávio Nogueira Ribeiro de Luna
Dados Não Estruturados · UFPB · 2026

8
palestras da FOSDEM 2025 e 2026

3,3 h
de áudio e vídeo analisados

320
telas lidas pelo OCR

O que esta etapa investiga

Numa palestra sobre IA no desenvolvimento, o que ela mostra, como ela soa e o que ela diz?

Por que palestras da FOSDEM

- A palestra junta imagem e som no mesmo relógio: a tela, a voz e o que o palestrante diz.
- A FOSDEM grava quase mil palestras por ano e publica a agenda em XML, com licença aberta.
- Cada vídeo tem uma legenda oficial, que dá para comparar com a transcrição do Whisper.

1.944
palestras com vídeo

27
com IA no título

8
passam nas regras



8 telas de cada palestra, com a moldura na cor do tipo que o OCR leu.

Das 27 com IA no título, só 8 falam de usar IA para desenvolver software. As outras tratam de servidor de modelo, dataset, filtro de spam e até de mouse antigo.

Teoria e parâmetros

O mesmo arquivo de vídeo, lido em três frentes: a imagem, o som e o texto

1 OpenCV

- Vídeo é uma pilha de imagens, e cada quadro é uma matriz de pixels.
- Diferença entre quadros: quanto o slide mudou, de 0 a 255.
- Canny: marca onde o brilho muda de repente, como na borda de uma letra.
- YuNet: rede neural que acha rostos na imagem da câmera.

2 librosa

- Som é uma lista de números: 16 mil amostras por segundo.
- Quadros de 25 ms, um a cada 10 ms: energia, espectrograma Mel e MFCC.
- Pausa longa: 0,7 s ou mais de silêncio entre duas falas.
- YIN: acha a altura da voz (F0) pelo tempo que o som leva para se repetir.

3 OCR e Whisper

- RapidOCR: uma rede neural acha o texto, e outra lê cada linha.
- Pelo texto e pelo brilho, a tela vira texto, visual, código ou interface.
- Whisper: escreve a fala, com a lista de nomes de ferramenta.
- Cada frase recebe o tipo da tela e a voz do mesmo segundo.

Parâmetros do projeto

Vídeo: 1 quadro por segundo · troca de slide: diferença > 6 · tela: 3 s parada · Canny 100 e 200 · confiança ≥ 0,6 · código: escura ou 15% das linhas

Som: 16 kHz · quadro de 25 ms a cada 10 ms · silêncio: 35 dB abaixo do pico ou até 10 dB acima do ruído · pausa ≥ 0,7 s · F0 de 65 a 400 Hz (YIN)

Implementação 1: OpenCV

Arquivo quadros.py: um quadro por segundo, recortado em slide e câmera

```
for segundo, quadro in percorrer(caminho):  # 1 por s
    slide = recortar(quadro, config.REGIAO_SLIDE)
    camera = recortar(quadro, config.REGIAO_CAMERA)
    dif = cv2.absdiff(mini, anterior)[mascara].mean()
    if dif > config.LIMIAR_TROCA:  # 6 de 255
        inicio_da_tela = segundo
    _, rostos = detector.detect(camera)  # YuNet
```

absdiff subtrai, pixel a pixel, o slide de agora do slide de um segundo antes. A máscara apaga o canto em que a câmera fica por cima do slide. Média acima de 6: o slide trocou.

Onde aprender

docs.opencv.org, os tutoriais oficiais do OpenCV em Python



ROSTO ACHADO EM 96 QUADROS DA CÂMERA

20 com o Haar cascade, de 2001

79 com o YuNet, rede neural de 2023

Implementação 2: librosa

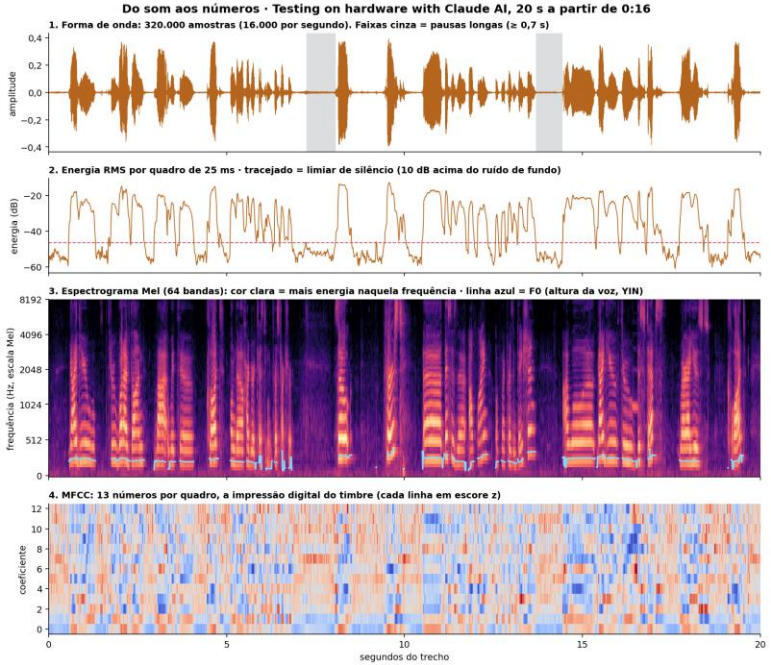
Arquivo sinal.py: o som do vídeo, cortado em 100 quadros por segundo

```
rms = librosa.feature.rms(y=sinal, frame_length=400,
                          hop_length=160)[0]
energia_db = librosa.amplitude_to_db(rms, top_db=None)
f0 = librosa.yin(sinal, fmin=65, fmax=400, sr=16000,
                 frame_length=1024, hop_length=160)
pelo_pico = energia_db.max() - 35  # abaixo do pico
pelo_piso = np.percentile(energia_db, 5) + 10  # ruído
silencio = energia_db <= max(pelo_pico, pelo_piso)
```

Cada quadro tem 400 amostras (25 ms), e um novo começa a cada 160 (10 ms). Silêncio: 35 dB abaixo do pico ou até 10 dB acima do ruído, o que marcar mais. Pausa longa: 0,7 s ou mais.

Onde aprender

librosa.org/doc/latest/tutorial.html, o tutorial oficial do librosa



PICO DE MEMÓRIA PARA MEDIR O SOM, EM MB

689 5 minutos, de uma vez só

221 50 minutos, um minuto por vez

Implementação 3: OCR e tipo de tela

Arquivo leitura.py: o que está escrito na tela e o que é dito no mesmo segundo

tela parada 3 s → **acha o texto** → **lê cada linha** → **conta linhas** → **tipo de tela**

```
if palavras < 10:
    return "visual"            # foto, meme
if linhas >= 50 or (escura and linhas >= 30):
    if escura or fracao_codigo >= 0.15:
        return "código"
    return "interface"         # GitHub, n8n
return "texto"
```

- Slide é feito para ser lido do fundo da sala: poucas linhas de letra grande. Editor e site têm dezenas de linhas miúdas.
- Conferido à mão: 48 de 48 nas telas usadas para escolher os limites, 29 de 32 nas sorteadas.

Onde aprender: github.com/RapidAI/RapidOCR, o OCR usado aqui

NA TELA (OCR)

Claude Hardware Testing Infrastructure

NOSSA TRANSCRIÇÃO (WHISPER COM A LISTA)

Guide you through what I've done with **Claude**
on the hardware testing infrastructure.

LEGENDA OFICIAL DA FOSDEM

try to guide you through what I've done but
with the **cloth** on the hard work testing

44
nomes só na nossa transcrição

0
nomes só na legenda oficial

Diário de bordo

Quatro erros que apareceram na implementação, e o que cada um exigiu

1. **O classificador achava 3 telas de código em 320**

   Contar linhas resolveu: 63 telas de código, 29 de 32 certas na conferência

2. **A lista de nomes acerta "cloth" e inventa "Claude striked"**

   33 erros da legenda corrigidos e 6 erros nossos, como OpenAPI virando OpenAI

3. **A sala barulhenta escondia as pausas**

   Limiar também 10 dB acima do ruído: o Rspamd foi de 0,3 para 4,3 pausas por minuto

4. **O "Gemini" escrito na tela era o botão do navegador**

   31 das 34 telas com Gemini mostram o botão do Chrome

O erro 2 tem dois lados: a lista acerta e inventa

Ela corrige 33 nomes que a legenda oficial errou, como "cloth" no lugar de Claude, 11 vezes numa palestra só.

E também inventa 6, como "Claude striked" no lugar de "CrowdStrike".

Toda ajuda ao modelo puxa os sons parecidos para as palavras dela: é preciso medir o ganho e o custo.

Antes e depois de cada correção

Telas de código

3 → 63

Pausas por minuto no Rspamd

0,3 → 4,3

Gemini na tela (o modelo)

34 → 3

Demonstração

python main.py: menu com 11 opções e o pipeline completo, tudo em cache, roda sem internet

3

Um quadro em números

Regiões, diferença, bordas e rostos: Haar contra YuNet

5

O som em números

Onda, energia, pausas, espectrograma e altura da voz, e ouvir o trecho

11

Busca KWIC

Padrão claude na fala e na tela, e abrir o momento 6

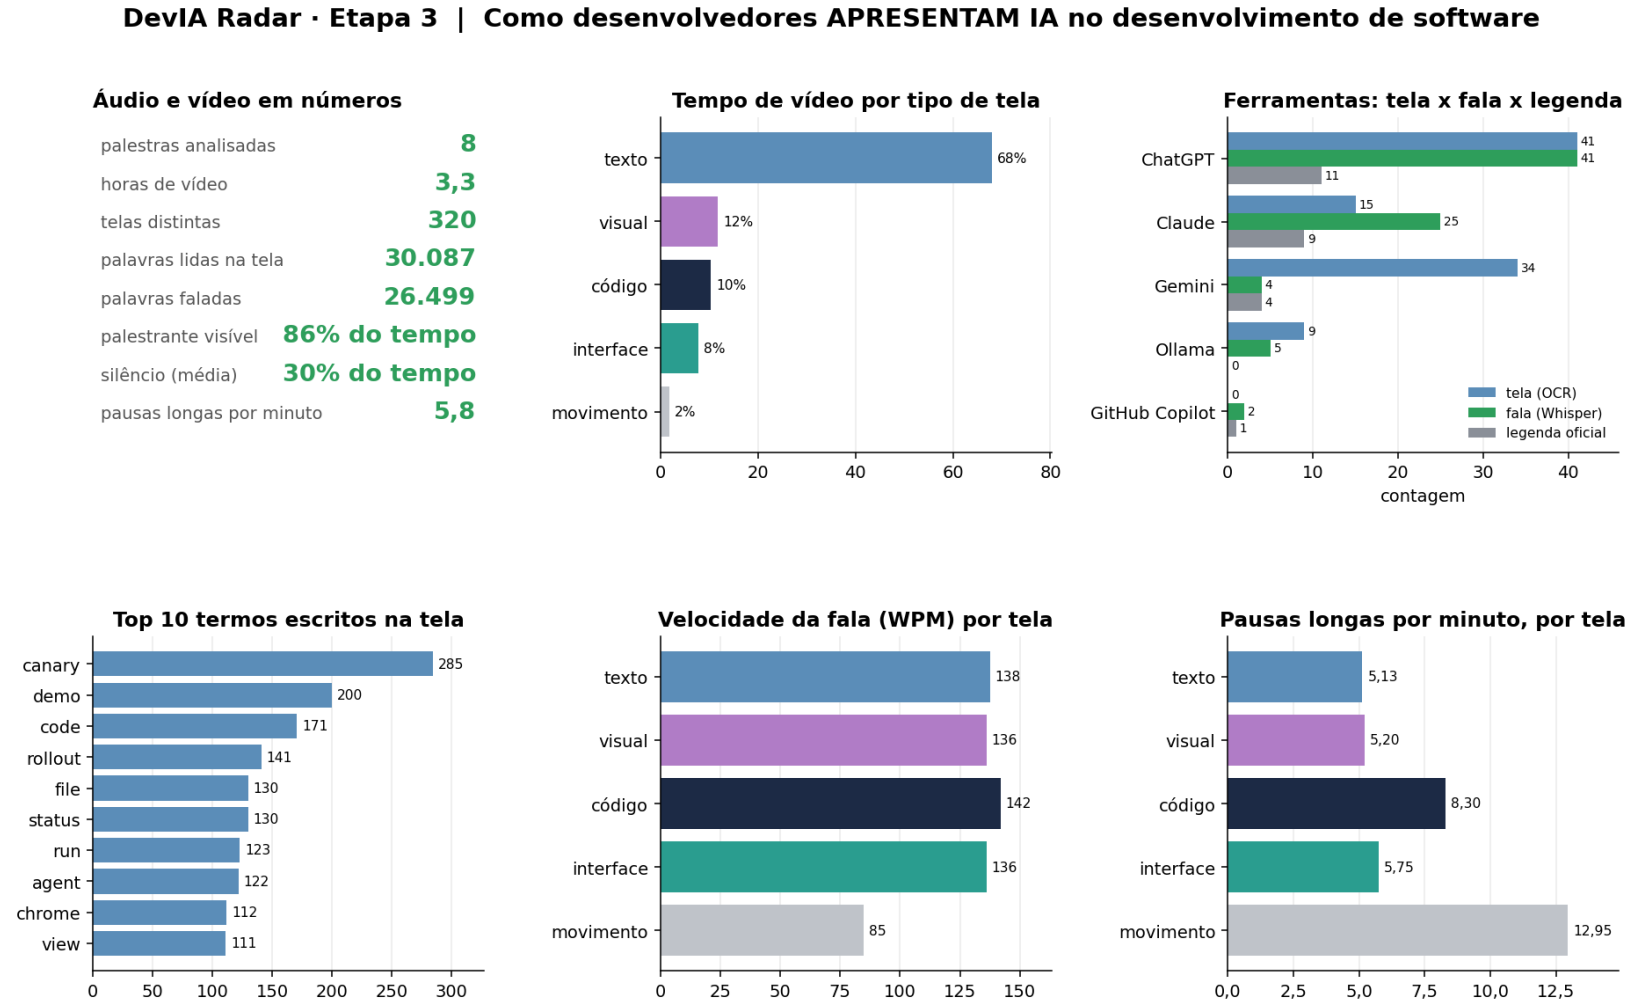
10

Dashboard

Os 11 gráficos em uns 16 s, com o dashboard e o painel final

```
DevIA Radar - Etapa 3 (áudio e vídeo) - UFPB
estado: vídeo:8 | som:8 | análise:ok
----------------------------------------
 [1]  Coletar palestras (agenda XML)
 [2]  Ver resumo das palestras
 [3]  Demonstrar um quadro (OpenCV)
 [4]  Extrair características visuais
 [5]  Demonstrar o som (librosa)
 [6]  Medir o som de todas
 [7]  Demonstrar tela, fala e legenda
 [8]  Ler as telas e transcrever
 [9]  Analisar tela, voz, ferramentas e fala
 [10] Gerar gráficos e painel
 [11] Buscar na fala e na tela (KWIC)
 [0]  Rodar o pipeline completo
 [r]  Recoletar do zero
 [s]  Sair
```

Resultados



Dashboard da opção 10: tipo de tela, ferramentas, termos da tela, velocidade da fala e pausas por tela.

A tela é quase toda slide

80% do tempo é slide: 68% de texto e 12% visual. Captura de ferramenta: 18%.

O tom vem de quem fala

O slide visual parecia mais emotivo, mas 141 das 193 frases ditas com ele são de uma palestra só.

A voz não segue o tom

Correlação entre o sentimento da frase e a voz: +0,005 na energia e −0,008 na altura.

Ressalva: são 8 palestras. 34 das 38 frases com ChatGPT vêm de uma só, que constrói um proxy do ChatGPT.

Limitações assumidas

8 palestras: todas as que passam nas regras

A ferramenta mais citada segue o tema de uma palestra.

O tempo de captura é um piso

3 das 32 telas da conferência eram capturas curtas lidas como slide.

A legenda oficial também é automática

A comparação mede o efeito da lista. Nenhuma das duas é gabarito.

As três etapas

1

Texto: 979 issues

34% positivas, 25% negativas. ChatGPT lidera, com 30%.

2

Significado: as mesmas 979 issues

Pipeline do spaCy, embeddings e transformer.

3

Áudio e vídeo: 8 palestras

25% positivas, 9% negativas. ChatGPT lidera, com 51%.

A reclamação mora no texto: 25% das frases das issues são negativas, contra 9% na fala das palestras.